BME 个人科研 Agent 方案：能力清单与系统设计

版本 v1.0 ｜ 2026 年 10 月 ｜ 适用对象：生物医学工程（BME）方向、以个人为主推进课题的研究者

0. 一句话结论

一个合格的个人科研 Agent，不是“更会聊天的大模型”，而是一个长期记得你整个课题、会主动盯进度、会在你犯错前拦住你、会拿证据反驳你的**“虚拟师兄 + 实验秘书 + 审稿人”**。它比 Claude Code、Codex、AI PPT、Deep Research 这类通用工具强，不是因为底层模型更聪明（大家调用的都是同一批模型），而是因为它多了四样东西：课题级长期记忆、**BME** 领域工具箱、实验闭环（做完实验回来更新判断）、主动提醒与反向引导。

本方案基于对 Google DeepMind Co-Scientist（Nature 2026）、FutureHouse Robin 与 Edison Kosmos、Stanford Biomni、Sakana AI Scientist、Claude Code / Codex 生态、主动式科研助手 Omakase，以及 LAB-Bench、BioProBench、BenchBench-Protocol 等湿实验评测的公开资料整理，参考链接见附录 C。

1. 调研结论：现在的“AI 科学家”能做到什么、缺什么

系统	擅长	对一人 **BME** 课题的不足
Google Co-Scientist（Nature 2026）	多智能体生成、互评、锦标赛排序、进化假设；在药物重定位、新靶点、耐药机制上有实验验证	只做“想法”，不陪你做实验、不管你的进度和数据
FutureHouse Robin / Edison Kosmos	文献 + 数据分析闭环；Kosmos 用“结构化世界模型”维持长程连贯，单次读约 1500 篇论文、跑约 4.2 万行代码	独立专家核验：报告陈述整体 79.4% 正确，但“综合解读类”陈述只有 57.9% 正确——越往结论走越需要人把关
Stanford Biomni	通用生物医学 Agent：150 个专用工具、105 个软件包、59 个数据库（UniProt、PDB、GEO、ClinVar、ChEMBL、ClinicalTrials.gov 等）	偏分子/组学，对器械、材料、信号、影像、力学等 BME 工程侧覆盖弱；不懂你的课题历史
Sakana AI Scientist v2（已发表于 Nature）	机器学习方向从想法到论文全自动，论文通过了同行评审	只限计算实验，湿实验无能为力
Claude Code / Codex CLI	写代码、跑分析、Skills / MCP / 子智能体可扩展，是搭 Agent 的最好“底座”	本身是通用编程助手，没有科研流程、没有领域规范、不会主动找你
Deep Research 类产品	一次性多源检索 + 长报告	你要自己把课题压缩成一句话去问；报告长而不可执行
AI PPT / 写作工具	出稿快	只解决最后一步，且容易编造引用
Omakase（2026 研究原型）	监控你的项目文档，自动发起文献查询，把长报告提炼成“针对你项目的可执行建议”，并能用文献反驳你的论断	只覆盖文献环节，是本方案“主动性”设计的重要参考

湿实验是当前 **AI** 的最大短板，方案必须针对性设计：

- BioProBench：模型直接生成实验方案时，必要步骤的召回率低于 43%；即便接入方案语料库检索，仍会漏掉约 38% 的必要步骤。

- LAB-Bench 的 ProtocolQA（方案纠错）上，主流模型准确率大约在 50%–60%。
- BenchBench-Protocol（Benchling，2026）：模型的建议“纸面上合理”，但会忽略仪器校准、把明显不纯的样品当纯品、忽视手法细节。
- SycEval（Stanford）：GPT-4o、Claude Sonnet、Gemini 1.5 Pro 在被用户反驳时出现“附和”的比例约 58%。一个只会顺着你说的 Agent 会放大错误。

由此得出的设计原则： Agent 负责“想全、查全、算对、记全、提醒到”，人负责“动手、判断、拍板、担责”。实验方案永远以已发表/实验室验证过的方案为底稿，Agent 做补全和纠错，不从零生成。

2. 定位：它是什么，不是什么

它是：

- 你课题的“第二大脑”：记得每一个假设、每一次实验、每一次失败和原因、导师的每条意见。
- 你的实验秘书：排期、倒计时、试剂与设备提醒、记录、复盘。
- 你的“Reviewer 2”：在你投入时间和样本之前，先挑毛病。
- 你的分析员和写作助手：数据处理、统计、作图、论文/基金/专利初稿。

它不是：

- 不是替你做实验、替你下结论、替你当作者的“全自动科学家”。
- 不是只会附和的聊天机器人：遇到设计缺陷必须明确反对。
- 不是数据生成器：绝不编造数据、补齐缺失值去“凑显著”。

3. 核心能力清单（12 大模块）

下表是“合格线”。打 ★ 的是让它明显强于通用工具的关键能力。

模块	必备能力	产出物
★1 课题大脑（长期记忆）	结构化记录研究目标、假设树、实验记录、结果、失败原因、决策及理由、导师意见、截止日期；每次对话前自动加载相关上下文	课题知识库、假设树、决策日志、失败库
2 文献情报	检索 PubMed、Europe PMC、OpenAlex、Semantic Scholar、arXiv/bioRxiv/medRxiv、IEEE Xplore、专利库、ClinicalTrials.gov；全文阅读含图表；每条引用必须能打开核验（DOI/PMID）	文献卡片、综述矩阵、每周文献雷达
★3 假设与选题	生成多个竞争假设 → 互相批判 → 排序（参考 Co-Scientist 锦标赛机制）；新颖性查重；可行性评估（设备、经费、周期、技能）	假设排行榜、选题评估表
★4 实验设计	样本量/功效分析、对照组设计（阴性/阳性/假手术/载体）、随机化与盲法、DOE（正交/响应面）、变量与混杂控制、预注册；按 ARRIVE 2.0 等规范自查	实验设计书、样本量计算书、预注册草稿
★5 失败预演（Pre-mortem）	实验开始前列出“这次最可能失败的 10	风险清单、预防清单

	个原因”并逐条给预防措施；对照你自己的失败库和文献常见坑	
6 实验陪跑	把方案拆成逐步检查表；计时与关键节点提醒；稀释/浓度/摩尔/细胞铺板/剂量换算计算器；记录实际操作偏差	当日实验检查表、电子实验记录
★7 故障排查	结果异常时按“试剂→样品→仪器→操作→设计→分析”顺序排查，结合失败库和文献，给出最小代价的验证实验	排查树、下一步验证建议
8 数据分析	Python/R 沙箱执行；统计检验选择与前提检查；图像分析（ImageJ/Fiji、CellProfiler）；信号处理（MNE、SciPy）；影像（3D Slicer、MONAI）；力学/仿真（FEBio、COMSOL 后处理）；全部脚本留档可复现	分析脚本、图表、统计报告
9 写作与发表	论文各部分初稿、方法学按规范清单写全、图注、投稿信、基金本子、专利交底书、组会/答辩 PPT；模拟审稿与回复审稿意见	文稿、审稿模拟报告、回复信
10 合规与伦理	判断是否需要伦理审批（人体/动物/人类遗传资源）、生物安全等级、医疗器械法规路径（NMPA/FDA、ISO 10993 生物相容性、ISO 13485、IEC 62304、IEC 62366-1）；患者数据脱敏	合规检查表、伦理申请材料草稿
11 项目管理	里程碑、甘特图、试剂库存与有效期、设备预约、经费台账、论文/会议/基金截止日期	周计划、风险看板
★12 主动性与反向引导	事件触发的主动提醒；对你的决定提出质疑；苏格拉底式追问；知道何时保持沉默	见第 4 章

3.1 BME 细分方向需要的专业工具包

通用 Agent 的最大缺口在这里。建议按你的方向挑 1–2 个包先做深。

方向	Agent 需要掌握的工具/知识
生物材料与组织工程	材料表征解读（SEM、XRD、FTIR、流变、力学测试）；降解与释放动力学拟合；细胞实验（CCK-8、活死染色、qPCR、免疫荧光）定量；ISO 10993 系列
医学影像与 AI	DICOM/NIfTI 处理；3D Slicer、MONAI、nnU-Net；数据划分防泄漏；TRIPOD+AI、CLAIM、STARD-AI 报告规范
生物信号与可穿戴	ECG/EEG/EMG/PPG 预处理与特征提取（MNE、NeuroKit2）；运动伪影；信噪比评估；IEC 60601 电气安全常识
神经工程 / 脑机接口	电极阻抗、刺激参数安全阈值、解码模型评估、在体实验与 IACUC/动物伦理
生物力学	有限元建模（FEBio、Abaqus 思路）、材料本构参数、网格收敛性检查、实验-仿真对标
生物传感与微流控	灵敏度/检出限/线性范围/选择性计算；校准曲线；流场仿真；批间差异
药物递送与纳米医学	粒径/PDI/zeta 电位、包封率、释放曲线拟合；

	PubChem/ChEMBL 查询
医疗器械研发	设计控制、需求追溯矩阵、风险管理（ISO 14971）、注册路径判断（NMPA 分类、FDA 510(k)/PMA/IDE）
计算与系统生物学	组学数据分析、通路富集、数据库查询（可直接复用 Biomni 的工具与数据库接口）

4. 主动性与反向引导：让它像“真人搭档”的关键

这是你最在意的效果，也是它和所有“你问它答”型工具的根本区别。设计参考了 Omakase（监控项目文档、主动发起查询）、PASK（需求检测 + 长期记忆 + 主动执行）以及“主动记忆 Agent”研究——后者发现，只在关键时刻注入提醒，效果优于“一直提醒”和“从不提醒”。

4.1 主动触发器（它什么时候会主动找你）

触发事件	**Agent** 的主动动作
你写下一个新实验计划	自动做样本量检查、对照组检查、失败预演；缺项直接标红
实验日前一天	推送明日检查表：试剂是否够、是否过期、设备是否已预约、细胞/动物状态是否就绪
实验进行中	按方案节点计时提醒（孵育、离心、换液、取材时间点）
实验结果上传	自动分析 → 与预期对比 → 若异常则启动故障排查 → 更新假设树的置信度
连续两次同类失败	主动叫停：“建议先做最小验证实验，再继续消耗样本”
文献雷达发现相关新论文	只推送与你当前假设直接相关的 1–3 篇，并说明“它支持还是反驳你的哪个假设”
截止日期临近	倒排计划，指出关键路径上已经落后的任务
你很久没更新某条线	询问是放弃、搁置还是遗忘，并记录原因
你准备下结论或写论文	自动跑“结论-证据”对照：每个结论背后是哪组数据、n 是多少、是否预先设定
涉及人体/动物/患者数据	先提示伦理与数据合规，未确认前不进入下一步

4.2 反向引导规则（防止它变成“马屁精”）

把下面这些写进 Agent 的系统规则，并定期抽查：

1. 先质疑再执行：对每个实验设计，至少提出一个最强反对意见和一个替代方案。
2. 苏格拉底式追问：“你的阴性对照是什么？”“如果结果是阴性，你能得出什么结论？”“这个效应量是从哪来的？”
3. 不轻易改口：你反驳它时，必须要求你给出证据；没有新证据就坚持原判断，并说明理由。
4. 分清三类陈述：每句话标注“来自文献 / 来自你的数据 / 是推测”，推测类必须明说。
5. 主动报坏消息：数据不支持假设时第一时间说，不包装、不找补。
6. 拒绝 **p-hacking**：不接受“换个检验方法再试试”“去掉几个离群点看看”这类请求，除非预先设定或有正当理由并记录在案。
7. 知道何时沉默：提醒分为“必须处理 / 建议关注 / 仅记录”三级，每天主动打扰不超过设定次数，避免提醒疲劳。

4.3 一天的样子（示例）

- 早上：推送“今日三件事”+ 一篇与你假设直接相关的新文献摘要（附支持/反驳判断）。
- 实验前：你拍照上传试剂标签，它核对批号、有效期、浓度并生成当日检查表。
- 实验中：按节点计时提醒；你语音说“第 3 孔加样多了”，它自动记入偏差记录。
- 下午：上传荧光图，它批量定量、出图，并提示“对照组荧光强度比上周低约 30%，建议检查抗体批次”。
- 晚上：生成当日实验记录、更新假设树，并列出“明天开始前你必须决定的一件事”。
- 每周：周报 + 进度风险 + “本周最值得怀疑的一个结论”。

5. 它如何真正提高实验成功率

机制	解决的问题
功效分析 + 预注册	样本量不够、事后改分析导致结果不可信
对照组与盲法强制检查	设计缺陷导致实验白做
失败预演 + 个人失败库	重复踩同一个坑
以验证过的方案为底稿 + 逐步检查表	AI 生成方案漏步骤（BioProBench 显示漏步骤是主要失败模式）
预实验（Pilot）建议	大批量投入前先用小样本验证关键参数
试剂/设备/细胞状态前置检查	非科学原因的失败（过期、没预约、细胞代数过高）
结构化故障排查	失败后盲目重复
结论-证据对照	过度解读、把探索性结果当确证性结果

6. 系统架构

6.1 分层设计

层	内容	推荐实现
交互层	手机端随时可用（语音、拍照、文件）；电脑端深度工作	飞书/企业微信/Telegram 机器人 + Web 看板；电脑端 Claude Code / Codex / Cursor
编排层	主 Agent 负责理解意图与分派；子 Agent 各司其职；定时任务驱动主动性	Claude Agent SDK、OpenAI Agents SDK 或 LangGraph；定时器（cron）
记忆层	结构化数据库（实验、样本、试剂、决策）+ 文献/笔记向量库 + 课题“世界模型”文档	SQLite/PostgreSQL + 向量库（Chroma/pgvector）+ Markdown 课题档案
工具层	文献检索、文献管理、代码执行、数据库查询、日历、电子实验记录	MCP 服务器：PubMed、OpenAlex、Semantic Scholar、Zotero、Jupyter、日历；Biomni 工具集
模型层	多模型按任务路由；可接中转站	自建 LiteLLM 或 New-API 网关（见第 7 章）
安全与审计层	每次调用的模型、提示词、输出、引用全部留档；敏感数据隔离	调用日志 + 引用核验器 + 数据脱敏

6.2 子 Agent 分工（“虚拟课题组”）

角色	职责
项目秘书	记忆维护、日程、提醒、周报
文献官	检索、精读、引用核验、文献雷达
假设官	生成与排序假设、新颖性检查
实验设计官	设计、样本量、对照、失败预演、检查表
统计官	检验选择、前提检查、效应量、多重比较校正
数据分析官	写脚本跑分析、出图、可复现留档
批判官（Reviewer 2）	专门挑错，对所有重要产出做独立审查
写作官	论文/基金/专利/PPT 初稿
合规官	伦理、生物安全、法规、数据隐私

批判官最好使用与执笔 Agent 不同厂商的模型，交叉验证能减少同一模型的系统性盲区。

7. 关于接入 API 中转站

你提到会接中转站那一批 API，这完全可行（大部分中转站都兼容 OpenAI 接口格式），但科研场景有几个必须注意的点：

风险	说明	对策
数据泄露	中转站能看到你发出的全部内容	未发表数据、患者数据、专利核心内容不走第三方中转；用官方 API 或本地模型
模型被替换或降级	部分中转站会用便宜模型冒充高端模型	准备一套固定的“验真测试题”定期抽测；记录每次返回的模型标识
稳定性	渠道随时可能失效	配置多条渠道 + 自动故障切换
可复现性	不知道到底用了哪个模型版本，论文方法学写不清楚	日志记录模型名、版本、时间、参数
合规	涉及人类遗传资源、患者隐私的数据有法律约束	敏感数据本地处理，只把脱敏后的结果发给云端模型

推荐做法：在自己的电脑或服务器上部署一个网关（LiteLLM 或开源 New-API），把官方 API 和各家中转站都接到网关后面，Agent 只连网关。这样可以统一做路由、限额、故障切换、日志和敏感词拦截，换渠道不用改 Agent 代码。

按任务选模型（示例策略）：

任务	模型档位
假设生成、实验设计、批判审查、故障排查	最强推理模型（两家不同厂商交叉）
写代码、跑分析	强编程模型
文献初筛、摘要、格式整理、提醒文案	便宜快速模型
图片/图表/凝胶/荧光图理解	多模态模型
敏感数据处理	本地开源模型

8. 与市面工具的对比

维度	通用聊天 / AI PPT	Claude Code / Codex	Deep Research	本方案 Agent

记得整个课题历史	弱	依赖手写说明文件	无	★ 结构化长期记忆
主动提醒	无	无	无	★ 事件 + 定时触发
反驳你	容易附和	偶尔	不针对你	★ 规则化反向引导
实验设计与统计把关	泛泛而谈	能算不会管	无	★ 强制检查清单
湿实验陪跑与排查	无	无	无	★ 检查表 + 失败库
BME 领域工具	无	需自己接	无	★ 预装领域工具包
引用可靠性	常编造	视配置	较好	★ 强制核验 DOI/PMID
写代码跑分析	弱	强	无	强（底座就是它们）

结论：用 **Claude Code / Codex** 当“手”，用本方案的记忆、流程、领域工具和主动机制当“脑和习惯”，这是一个人就能搭出来、并且确实比单独使用任何一个工具都强的组合。

9. 边界与红线

8. 绝不编造数据、图像或引用；找不到就说找不到。
9. 每条文献引用必须能通过 DOI/PMID 打开核验，核验失败的自动删除并告知。
10. 结论由你下，Agent 只给证据和置信度。
11. 涉及人体、动物、人类遗传资源、患者数据的研究，未完成伦理与合规确认前不推进。
12. 不帮忙做 p-hacking、不选择性报告结果。
13. 保留全部提示词与输出记录。Nature 等期刊要求披露大模型使用情况，不接受 AI 为作者，并鼓励提交提示词与回复记录。
14. 生物安全：不提供可能被滥用的危险病原体或毒素相关操作细节。

10. 落地路线（分阶段）

阶段	目标	交付内容	验收标准
阶段一：最小可用版	有记忆、能检索、会提醒	课题档案模板 + 文献检索 MCP + 引用核验 + 每日/每周推送 + 实验记录	能准确复述你课题现状；引用 100% 可打开
阶段二：实验把关	提高实验成功率	实验设计检查清单、样本量计算、失败预演、检查表、失败库、批判官	每个新实验都经过检查；重复失败明显减少
阶段三：分析与写作	数据到论文的闭环	数据分析沙箱、领域工具包、写作官、审稿模拟	分析脚本可一键复现；论文方法学按规范清单无缺项
阶段四：主动与进化	像真人搭档	事件触发器、假设树置信度更新、文献雷达、提醒分级与降噪	你觉得提醒“有用的多、烦人的少”

11. 怎么评估它合不合格

指标	含义
引用准确率	引用真实存在且内容对得上的比例，目标 100%
实验一次成功率	不因可预防原因失败的实验比例，与使用前对比
设计缺陷拦截数	实验前被它发现并修正的问题数量
想法到实验的周期	从提出假设到第一次正式实验所需的工作量
提醒命中率 / 误报率	有用提醒占比；被你标为“无用”的提醒占比

坚持正确判断的比例	你无证据反驳时它不改口的比例（用测试题抽查）
可复现率	分析结果能被脚本重新跑出的比例

附录 A：课题档案模板（Agent 的“世界模型”）

- 研究总目标与科学问题
- 假设树：每个假设的状态（待验证 / 支持 / 反驳 / 搁置）、置信度、支撑证据
- 实验登记：编号、目的、对应假设、设计、样本量、日期、结果、偏差、结论
- 失败库：现象、根因、预防措施
- 决策日志：日期、决定、理由、谁拍板
- 资源：试剂（批号、有效期、库存）、设备、样本、经费
- 时间线：里程碑、截止日期、组会、投稿、基金
- 导师与合作者意见记录

附录 B：系统规则核心片段（可直接放进 Agent 的系统提示词）

- 你是我的 BME 课题搭档，不是助手。你的首要目标是让我的研究结论真实、可复现。
- 回答前先读取课题档案中与问题相关的部分；不确定时先问我，不要猜。
- 对任何实验设计，先指出最大风险和缺失对照，再给方案。
- 每条事实标注来源：文献（附 DOI/PMID）、我的数据（附实验编号）、或推测。
- 我反驳你时，若我没有新证据，请坚持并解释；若有新证据，明确说明你为何改变判断。
- 发现我的数据不支持假设、计划有漏洞、或进度落后时，必须主动、直接地告诉我。
- 绝不编造数据、图片或文献；绝不协助选择性报告或事后调整分析以追求显著性。
- 涉及人体、动物、人类遗传资源或患者数据时，先确认伦理与合规状态。

附录 C：主要参考资料

- Google DeepMind. Co-Scientist: A multi-agent AI partner to accelerate research（2026）. https://deepmind.google/blog/co-scientist-a-multi-agent-ai-partner-to-accelerate-research/
- Accelerating scientific discovery with Co-Scientist. Nature（2026）. https://www.nature.com/articles/s41586-026-10644-y
- FutureHouse. Robin: end-to-end scientific discovery. https://www.futurehouse.org/research/demonstrating-end-to-end-scientific-discovery-with-robin-a-multi-agent-system
- Kosmos: An AI Scientist for Autonomous Discovery. arXiv:2511.02824. https://arxiv.org/abs/2511.02824
- Biomni: A General-Purpose Biomedical AI Agent（Stanford）. https://biomni.stanford.edu/；GitHub: snap-stanford/Biomni
- Sakana AI. The AI Scientist, published in Nature. https://sakana.ai/ai-scientist-nature/
- Omakase: proactive assistance for evolving scientific research projects. arXiv:2604.08898. https://arxiv.org/abs/2604.08898

- PASK: Intent-Aware Proactive Agents with Long-Term Memory. arXiv:2604.08000. https://arxiv.org/abs/2604.08000
- Remember When It Matters: Proactive Memory Agent for Long-Horizon Agents. arXiv:2607.08716. https://arxiv.org/abs/2607.08716
- LAB-Bench: Measuring Capabilities of Language Models for Biology Research. arXiv:2407.10362. https://arxiv.org/abs/2407.10362
- BioProBench: Benchmark in Biological Protocol Understanding and Reasoning. arXiv:2505.07889. https://arxiv.org/abs/2505.07889
- Benchling. Can LLMs work in the wet lab?（BenchBench-Protocol）. https://www.benchling.com/blog/can-llms-work-in-the-wet-lab
- SycEval: Evaluating LLM Sycophancy（Stanford, AIES）. https://ojs.aaai.org/index.php/AIES/article/view/36598
- Nature. Why AI cannot do good science without humans（2026）. https://www.nature.com/articles/d41586-026-01551-3
- Nature. AI scientists are changing research — institutions, funders and publishers must respond（2026）. https://www.nature.com/articles/d41586-026-00934-w
- Benefits and Risks of Using AI Agents in Research. PMC12872602. https://pmc.ncbi.nlm.nih.gov/articles/PMC12872602/
- Artificial Intelligence agents for biological research: a survey. PMC12936789. https://pmc.ncbi.nlm.nih.gov/articles/PMC12936789/
- ARRIVE guidelines 2.0. https://arriveguidelines.org/
- EQUATOR Network reporting guidelines（CONSORT-AI、TRIPOD+AI、STARD-AI 等）. https://www.equator-network.org/
- FDA. Overview of Device Regulation（QMSR 自 2026-02-02 起引用 ISO 13485）. https://www.fda.gov/medical-devices/device-advice-comprehensive-regulatory-assistance/overview-device-regulation
- LiteLLM AI Gateway. https://docs.litellm.ai/docs/simple_proxy
- awesome-research-agents（研究型 Agent 资源汇总）. https://github.com/chrisliu298/awesome-research-agents